VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ
FAKULTA INFORMAČNÝCH TECHNOLÓGIÍ

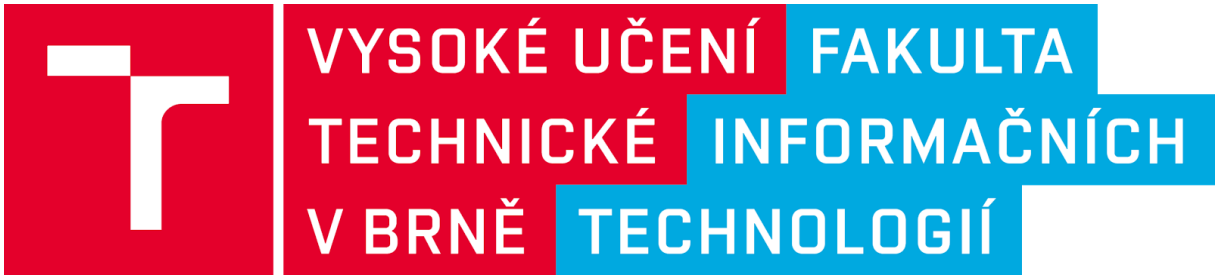

Dokumentácia k projektu do predmetu IFJ a IAL

Implementácia interpreta jazyka IFJ16

Tím 026, varianta *b/1/II*

25. novembra 2016

Členovia tímu:
Dávid Bolvanský (xbolva00), 20% - vedúci tímu
Juraj Dúbrava (xdubra03), 20%
Tamara Krestianková (xkrest07), 20%
Martin Marušiak (xmarus07), 20%
Veronika Svoradová (xsvora01), 20%

Rozšírenia – SIMPLE, BOOLOP

OBSAH

ÚVOD

Dokumentácia popisuje implementáciu interpreta jazyka IFJ16, ktorý je veľmi zjednodušenou podmnožinou jazyka Java SE 8^2. Jeho implementáciu sme rozdelili do 4 hlavných častí, ktoré budú bližšie popísané v ďalšej časti dokumentácie:

1. Lexikálny analyzátor
2. Syntaktický analyzátor
3. Sémantický analyzátor
4. Interpret

Zvolili sme si variantu b/1/II, ktorá obsahovala zadanie na implementáciu vyhľadávania podreťazca v reťazci s použitím algoritmu Boyer-Moore, implementáciu riadenia s využitím Quick sort algoritmu a implementáciu tabuľky symbolov pomocou tabuľky s rozptýlenými položkami. Jednotlivé implementácie týchto algoritmov nájdete v kapitole 2.

Súčasťou dokumentácie sú aj tri prílohy, ktoré obsahujú diagram konečného automatu špecifikujúceho lexikálny analyzátor, LL gramatiku a precedenčnú tabuľku, ktoré sú jadrom syntaktického analyzátora.

1 IMPLEMENTÁCIA INTERPRETA JAZYKA IFJ16

1.1 Lexikálna analýza

Lexikálny analyzátor (scanner) je implementovaný v súboroch scanner.c a scanner.h. Je to jediná časť celého interpreta, ktorá pracuje priamo so zdrojovým súborom. Jeho úlohou je načítať zdrojový kód, odstrániť zbytočné časti ako sú biele znaky a komentáre, a finálne previesť lexémy na tokeny. Token sa skladá z dvoch častí: typ a atribút. Typ tokenu sa určí aplikovaním konečného automatu (viď príloha č.1) na postupnosť znakov načítaných zo vstupu.

Pre podporu nekonečne dlhého reťazca sme vytvorili pomocnú knižnicu, ktorá je implementovaná v súboroch strings.c a strings.h, a ktorá nám umožňuje pracovať s potenciálne nekonečným reťazcom. Ak prijatá postupnosť znakov nie je platná pre žiadne pravidlo, dochádza k lexikálnej chybe pri spracovávaní zdrojového textu. Lexikálny analyzátor poskytuje funkciu get_next_token, ktorá je následne využívaná syntaktickým analyzátorom.

1.2 Syntaktická analýza (bez spracovania výrazu)

Syntaktický analyzátor (parser) kontroluje množinu pravidiel, ktorá určuje prípustné konštrukcie daného jazyka. Základné možné konštrukcie jazyka IFJ16 a prídavné konštrukcie, ktoré vyplynuli z voľby rozšírení SIMPLE a BOOLOP sú definované v LL gramatike (viď príloha č. 2). Samotná syntaktická analýza je riešená metódou rekurzívneho zostupu a je jadrom celého interpreta a spolupracuje s ostatnými časťami interpreta.

Kvôli špecifickým požiadavkám jazyka Java, a teda aj IFJ16 ako jeho podmnožinou, dochádza k parsovaniu v dvoch prechodoch v rámci syntaktického analyzátora. V prvom prechode získavame tokeny z lexikálneho analyzátora a zároveň ich ukladáme do poľa tokenov, ktoré je implementované v súboroch token_buffer.c a token_buffer.h. Ak nenastane žiadna chyba počas prvého prechodu, pokračujeme. V druhom prechode získavame tokeny z práve vytvoreného poľa tokenov. Priebežne sa v rámci prvého a druhého prechodu vykonávajú sémantické kontroly a generujú sa inštrukcie na inštrukčnú pásku. Po úspešnej syntaktickej a sémantickej analýze dochádza k samotnej interpretácii kódu.

1.3 Syntaktická analýza (spracovanie výrazu)

Spracovanie výrazov je úloha precedenčnej syntaktickej analýzy implementovanej v súbore expr.c. Precedenčná syntaktická analýza je riadená na základe precedenčnej tabuľky (viď príloha č. 3), ktorá popisuje prioritu spracovania jednotlivých operátorov a operandov. Vstupom analýzy sú tokeny zo špeciálneho poľa tokenov vytvoreného pre precedenčnú syntaktickú analýzu, tokeny získame funkciou get_next_token_psa.

Spracovávané vstupné tokeny sú počas analýzy ukladané na zásobík a vyhodnocovanie výrazu, ktorý vzniká na zásobníku je riadené precedenčnou tabuľkou. Dôležitou súčasťou spracovania výrazu je kontrola správnosti dátových typov nad ktorými sú uskutočňované jednotlivé aritmeticko - logické operácie a takisto syntaktické kotroly výrazu. V rámci priebežného spracovávania výrazu prebieha aj generovania 3-adresného kódu pre interpret.

1.4 Sémantická analýza

Úlohou sémantickej analýzy je preskúmať logický význam jednotlivých výrazov jazyka a zistiť ich platnosť pre daný programovací jazyk. Aj napriek tomu, že jazyk IFJ16 je podmnožinou jazyka Java, obsahuje isté špecifiká, ktorými sa od nej líši. Kľúčovým prvkom je spolupráca s tabuľkou symbolov. Z tejto tabuľky sa získavajú rôzne informácie a zároveň sa kontroluje resp. rozhoduje, či nedošlo k redeklarácií tried, premenných alebo funkcií. Zároveň sa kontroluje či nedošlo k typovej nekompatibilite pri priradení alebo vo výrazoch a taktiež prípadná nezhoda v počte parametrov funkcie, a rôzne iné sémantické kontroly.

1.5 Interpret

Interpret vykonáva inštrukcie, ktoré mu boli vygenerované v predošlých fázach. Inštrukciu reprezentujeme prostredníctvom 3-adresného kódu. Jednotlivé inštrukcie za sebou nasledujú v inštrukčnej páske, ktorú reprezentuje jednosmerne viazaný zoznam. Významovo rozlišujeme dva typy pások, globálnu a lokálnu (funkcie). Globálna inštrukčná páska sa začne vykonávať ako prvá, z nej je potom vykonaná inštrukčná páska funkcie run z triedy Main, ktorá môže vyvolať vykonanie inštrukčných pások ďalších funkcii. Z pások funkcií môžu byť taktiež volané ďalšie pásky funkcií až do ľubovoľného zanorenia. Vykonanie inštrukčnej pásky v rámci inej inštrukčnej pásky je implementované rekurzívne.

K tomu aby sme mohli volať funkcie, a neprepisovali pritom hodnoty v tabuľke symbolov, slúžia rámce, ktoré sa vytvárajú vždy pred volaním funkcie a zabezpečia uloženie parametrov a vytvorenie lokálnych premenných pre funkciu. Pred vykonaním inštrukcie je potrebne preložiť adresy jednotlivých operandov tak, aby sa v prípade ak ide o lokálnu premennú, odkazovali na príslušnú hodnotu v rámci. To uskutočňuje pomocou offsetov, ktorý je pre každú lokálnu premennú v danom rámci jedinečný. Po následnom preklade sa overí inicializácia operandov a následne vykoná inštrukcia.

2 VSTAVANÉ FUNKCIE

2.1 Algoritmy do predmetu IAL

2.1.1 Implementácia radenia (Quick sort)

Quick sort alebo "radenie rozdeľovaním" patrí medzi najrýchlejšie metódy radenia polí. Tento algoritmus funguje na veľmi jednoduchom princípe. Pomocou mechanizmu partition prehodí prvky do dvoch častí poľa tak, že v ľavej časti sú všetky prvky menšie alebo rovné určitej hodnote (pivot) a v pravej časti sú všetky prvky väčšie ako táto hodnota.

V našom prípade sme za pivot zvolili pseudomedián. Pseudomedián sme vyrátali ako sčítanie ľavej a pravej hranice reťazca. Tento súčet sa nakoniec podelí (div) číslom dva:

- pseudomedián = (ľavá hranica + pravá hranica) deleno (2).

Po rozdelení poľa na dve časti rekurzívne voláme funkciu pre opätovné radenie jednotlivých častí poľa. Celý algoritmus je uložený v súbore ial.c.

Priemerná doba výpočtu algoritmu Quick sort je v najlepšom prípade (O*(n*log(n))), no však pri nevhodnom tvare vstupných dát môže byť časová náročnosť tohto algoritmu až O(n^2). Autorom algoritmu z roku 1962 je Sir Charles Antony Richard Hoare, významná osobnosť v obore teórie a tvorby programov.

2.1.2 Implementácia vyhľadávania podreťazca v reťazci (Boyer-Moore)

Boyer-Moore algoritmus je jedným z najefektívnejších algoritmov pre porovnávanie reťazcov. Používa sa na vyhľadávanie podreťazca v inom reťazci. Je vhodný pri hľadaní dlhého podreťazca. Funguje na princípe spracovávania znakov v hľadanom reťazci sprava doľava. Ak dôjde k nezhode, nastáva posun. Čím dlhší je vyhľadávaný podreťazec, tým väčší počet znakov v reťazci je možné preskočiť a tým je kratšia doba spracovania.

Pre implementáciu algoritmu sa používajú dve heuristiky. Algoritmus berie ten z výsledkov dvoch heuristík, ktorý je výhodnejší. My sme použili obe, čím sa zvýšila efektivita algoritmu. Implementáciu môžete nájsť v súbore ial.c.

2.2 Implementácia tabuľky symbolov

Základom tabuľky symbolov je tzv. hashovacia tabuľka, ktorá je určená pre našu variantu zadania. Každá trieda má svoju tabuľku symbolov, v ktorej sú uložené informácie o statických (globálnych) premenných a funkciách. Rovnako ako triedy tak aj funkcie majú svoju tabuľku symbolov, ktorá obsahuje informácie o parametroch/lokálnych premenných a zároveň o ich počte.

2.3 Vstavané funkcie pre načítanie literálu a výpis termov

Medzi vstavané funkcie pre načítanie literálu a výpis termov patria nasledovné:
int readInt ( ) ; - funkcia prevedie načítaný reťazec na jedno celé číslo a vráti ho
double readDouble ( ) ; - funkcia prevedie načítaný reťazec na jedno desatinné číslo a vráti ho

Pri oboch funkciách nesmie byť vypustený žiadny biely znak ,takže formát vstupného reťazca musí odpovedať lexikálnym pravidlám pre daný literál, inak nastane chyba 7.
String readString ( ) ; - funkcia vráti zo štandardného vstupu načítaný reťazec, ktorý je ukončený koncom riadku alebo koncom vstupu
void print (term/konkatenácia) – ak sa jedná o term, funkcia vypíše hodnotu v danom formáte na štandardný výstup. Pokiaľ je term typu int alebo double, je najprv automatický prevedený na reťazec a až potom vypísaný. Parameter, ktorý obsahuje neprázdnu postupnosť termov oddelených operátorom + je výraz, ktorý bude najprv vyhodnotený a následne podľa pravidiel pre výpis termov aj vypísaný.

2.4 Vstavané funkcie pre prácu s reťazcom

Medzi vstavané funkcie pre prácu s reťazcom v našom projekte patria nasledovné:
int length (String s) - funkcia vráti dĺžku (počet znakov) reťazca zadaného parametrom "s"
String substr (String s, int i, int n) - funkcia vráti podreťazec zadaného reťazca "s". Hľadaný podreťazec má dĺžku "n" a začína na indexe "i" zadaného reťazca "s".
int compare (String s1, String s2) - funkcia lexikograficky porovnáva dva zadané reťazce "s1" a "s2" a vráti celočíselnú hodnotu: 0, ak sú reťazce "s1" a "s2" rovnaké,
1, ak je "s1" väčší ako "s2",
-1, v ostatných prípadoch
int find (String s, String search) - funkcia nájde prvý výskyt zadaného podreťazca "seach" v reťazci "s" a následne vráti jeho pozíciu. Ak sa jedná o prázdny reťazec, vyskytuje sa vždy v každom reťazci na indexe 0. V prípade, že zadaný podreťazec "search" nie je nájdený, funkcia vráti hodnotu -1. V našom zadaní sme využili metódu Boyer-Moorovho algoritmu, ktorá je podrobne opísaná v časti 3.1.2 a nachádza sa v súboroch ial.c a ial.h.
String sort (String s) - funkcia, ktorá zoradí znaky v danom reťazci tak, aby znak s nižšou ordinálnou hodnotou vždy predchádzal znaku s vyššou ordinálnou hodnotou. V našom projekte sme využili metódu Quick sort algoritmu, ktorý je podrobnejšie opísaný v časti 3.1.1 a nachádza sa v súbore ial.c.

3 PRÁCA V TÍME

Prácu v tíme sme si rozvrhli nasledovne, s tým, že niektoré časti sa prekrývali, resp. bolo nutné sa na nich spoločné dohodnúť, ako postupovať, aké budú rozhrania.

- **Dávid Bolvanský**: Lexikálna, syntaktická (bez výrazu), sémantická analýza
- **Juraj Ondrej Dúbrava**: Syntaktická analýza (spracovanie výrazu), tvorba LL gramatiky a precedečnej tabuľky
- **Martin Marušiak**: Generovanie kódu, návrh 3AK, interpret, hashovacia tabuľka
- **Tamara Krestianková, Veronika Svoradová**: IAL algoritmy, vstavané funkcie, testovanie a dokumentácia

4 ZÁVER

Všetci členovia tímu sa zhodneme, že sme pred týmto projektom nepracovali na ničom tak komplexnom a rozsiahlom, ako bol tento projekt. Získali sme nie len skúsenosti a vedomosti ohľadom tvorby interpretov/prekladačov, ale aj nové znalosti v programovaní v C a používaní GITu. Dôležité bolo aj naučiť sa spolupracovať medzi sebou a akceptovať požiadavky ostatných pri tvorbe ich častí interpretu. Našou miernou výhodou bolo, že sme mohli rýchlo riešiť problémy, kedže sme od seba nebývali ďaleko a mohli sme často osobne vykonzultovať daný problém.

5 REFERENCIE

[1] Prednášky, skriptá, podklady k predmetu IFJ a IAL

/*[2] Prof. Ing. Jan Maxmilián Honzík, CSc. Algoritmy IAL: Sudijní opora [online]. Verzia 16-D. 2016-11-30 [cit. 2016-12-5]. Dostupné z: https://wis.fit.vutbr.cz/FIT/st/ course-files-st.php/course/IAL-IT/texts/Opora-IAL-2016-verze-16D.pdf*/

[3] Hashovacia funkcia [online]. [cit. 2016-12-5]. Dostupné na internete: http://www.fit.vutbr.cz/study/courses/IJC/public/

[4] Quicksort algoritmus [online]. [cit.2016-12-5] Dostupné na internete: https://sk.wikipedia.org/wiki/Quicksort

6 PRÍLOHY

Príloha č.1: Diagram konečného automatu

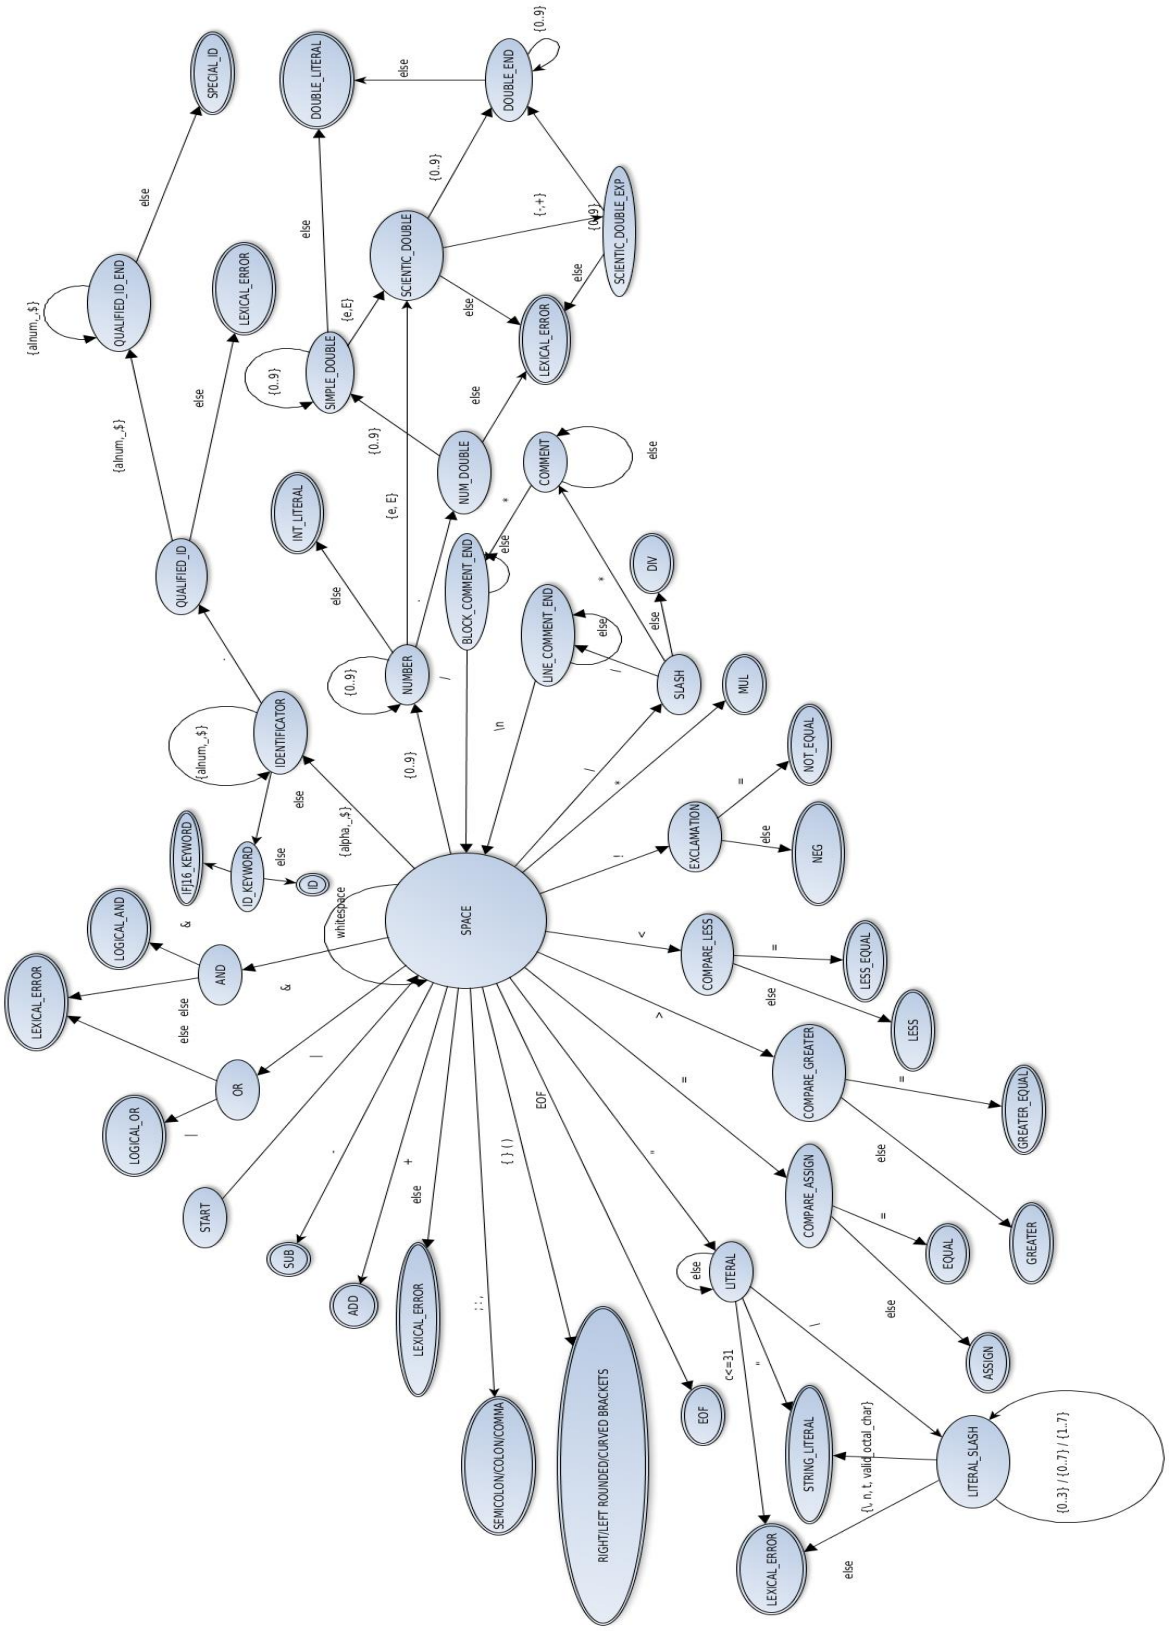

Príloha č.2: LL gramatika

<CLASS-LIST> -> CLASS ID { <CLASS-ELEMENT> } <CLASS-LIST>
<CLASS-LIST> -> EPSILON
<CLASS-ELEMENT> -> STATIC <DECLARATION-ELEMENT> <CLASS-ELEMENT>
<CLASS-ELEMENT> -> EPSILON
<DECLARATION-ELEMENT> -> <PARAM> <DECLARATION>
<DECLARATION-ELEMENT> -> VOID ID <METHOD-DECLARATION>
<DECLARATION> -> ;
<DECLARATION> -> = <E>;
<DECLARATION> -> <METHOD-DECLARATION>
<METHOD-DECLARATION> -> (<PARAM-LIST>) { <METHOD-ELEMENT> }
<ID> -> ID
<ID> -> SPECIAL_ID
<DATA-TYPE> -> INT
<DATA-TYPE> -> DOUBLE
<DATA-TYPE> -> STRING
<DATA-TYPE> -> BOOLEAN
<PARAM-LIST> -> EPSILON
<PARAM-LIST> -> <PARAM> <NEXT-PARAM>
<NEXT-PARAM> -> ,<PARAM> <NEXT-PARAM>
<NEXT-PARAM> -> EPSILON
<PARAM> -> <DATA-TYPE> ID
<CALL-ASSIGN> -> (<PARAM-VALUE>)
<CALL-ASSIGN> -> = <E>
<PARAM-VALUE> -> EPSILON
<PARAM-VALUE> -> <E> <NEXT-PARAM-VALUE>
<NEXT-PARAM-VALUE> -> ,<E> <NEXT-PARAM-VALUE>
<NEXT-PARAM-VALUE> -> EPSILON
<VALUE> -> EPSILON
<VALUE> -> = <E>
<METHOD-ELEMENT> -> <PARAM> <VALUE>; <METHOD-ELEMENT>
<METHOD-ELEMENT> -> EPSILON
<METHOD-ELEMENT> -> <ELEMENT-LIST> <METHOD-ELEMENT>
<ELEMENT-LIST> -> <STATEMENT>
<ELEMENT-LIST> -> {<STATEMENT-LIST>}
<STATEMENT-LIST> -> <STATEMENT> <STATEMENT-LIST>
<STATEMENT-LIST> -> EPSILON
<STATEMENT-LIST> -> {<STATEMENT-LIST>} <STATEMENT-LIST>
<STATEMENT> -> ;
<STATEMENT> -> <ID> <CALL-ASSIGN>;
<STATEMENT> -> IF (<E>) <CONDITION-LIST> <ELSE>
<STATEMENT> -> WHILE (<E>) <CONDITION-LIST>

<STATEMENT> -> RETURN <RETURN-VALUE>;

<RETURN-VALUE> -> EPSILON

<RETURN-VALUE> -> <E>

<ELSE> -> EPSILON

<ELSE> -> ELSE <CONDITION-LIST>

<CONDITION-LIST> -> {<STATEMENT-LIST>}

<CONDITION-LIST> -> <STATEMENT>

Príloha č.3: Precedenčná tabuľka

	+	-	*	/	(	)	<	>	<=	>=	==	!=	&&	||	ID	LIT	$	!
+	>	>	<	<	<	>	>	>	<	>	>	>	>	>	<	<	>	<
-	>	>	<	<	<	>	>	>	>	>	>	>	>	>	<	<	>	<
*	>	>	>	>	<	>	>	>	>	>	>	>	>	>	<	<	>	<
/	>	>	>	>	<	>	>	>	>	>	>	>	>	>	<	<	>	<
(	<	<	<	<	<	=	<	<	<	<	<	<	<	<	<	<	>	<
)	>	>	>	>		>	>	>	>	>	>	>	>	>				>
<	<	<	<	<	<	>	>	>	>	>	>	>	>	>	<	<	>	<
>	<	<	<	<	<	>	>	>	>	>	>	>	>	>	<	<	>	<
<=	<	<	<	<	<	>	>	>	>	>	>	>	>	>	<	<	>	<
>=	<	<	<	<	<	>	>	>	>	>	>	>	>	>	<	<	>	<
==	<	<	<	<	<	>	>	>	>	>	>	>	>	>	<	<	>	<
!=	<	<	<	<	<	>	>	>	>	>	>	>	>	>	<	<	>	<
&&	<	<	<	<	<	>	<	<	<	<	<	<	>	>	<	<	>	<
||	<	<	<	<	<	>	<	<	<	<	<	<	>	>	<	<	>	<
ID	>	>	>	>		>	>	>	>	>	>	>	>	>			>	
LIT	>	>	>	>		>	>	>	>	>	>	>	>	>			>	
$	<	<	<	<	<		<	<	<	<	<	<	<	<	<	<		<
!	>	>	>	>	<	>	>	>	>	>	>	>	>	>	<	<	>	<

<E> -> <E> + <E>

<E> -> <E> - <E>

<E> -> <E> * <E>

<E> -> <E> / <E>

<E> -> <E> < <E>

<E> -> <E> > <E>

<E> -> <E> <= <E>

<E> -> <E> >= <E>

<E> -> <E> != <E>

<E> -> <E> == <E>

<E> -> <E> && <E>

<E> -> <E> || <E>

<E> -> (<E>)

<E> -> !<E>

<E> -> ID

<E> -> SPECIAL_ID

<E> -> TRUE

<E> -> FALSE

<E> -> INT_LITERAL

<E> -> DOUBLE_LITERAL

<E> -> STRING_LITERAL